



**FACULDADE FIAP**

Curso de Inteligência Artificial

**Sprint #4 – IA Challenges & Solutions**

Relatório de Análise Crítica

SÃO PAULO

30/10/2023



**FACULDADE FIAP**

Curso de Inteligência Artificial

**Sprint #4 – IA Challenges & Solutions**

Relatório de Análise Crítica

Relatório de Análise Crítica do projeto John Deere + Projeto Drone para a disciplina de IA Challenges & Solutions do curso de Tecnologia em Inteligência Artificial Universidade FIAP.

**Green D'AI**

Lucas Bueno Taets Gustavo - 552162

Henrique Marra Barbosa - 97672

Arthur Hieda Cunha - 551882

Fabricio Yukio Yamashiro - 552188

Leonardo Vaidotas de Araújo - 550700

Professor: André Godoi Chiovato

Data: 30/10/2023

SÃO PAULO

2023

## **SUMÁRIO – Projeto John Deere**

**1. INTRODUÇÃO**

**2. DESCRIÇÃO DA SOLUÇÃO VENCEDORA**

**3. MOTIVOS DA ESCOLHA PELA JD**

**4. COMPARAÇÃO COM A ENTREGA DO SEU GRUPO**

**5. CONCLUSÃO**

## **1. INTRODUÇÃO**

Este relatório apresenta uma análise crítica do Challenge da John Deere realizado no curso de Tecnologia em Inteligência Artificial da Universidade FIAP. O desafio envolveu a criação de modelos de previsão de produção agrícola para atender às necessidades da JD, uma empresa do setor agrícola.

Neste contexto, nosso grupo teve a oportunidade de explorar e desenvolver soluções inovadoras e criativas. Ao final do desafio, foi anunciada a solução vencedora, que se destacou entre as demais. A tarefa que se apresenta agora é a análise crítica dessa solução, compreendendo os motivos que levaram a JD a escolher o grupo vencedor e, ao mesmo tempo, avaliar nossa própria entrega.

O foco desta análise recai sobre a solução vencedora, destacando seus pontos fortes, sua adequação ao negócio da JD e os desafios superados. Além disso, comparamos nossa entrega com a solução vencedora, identificando áreas de aprimoramento.

## **2. DESCRIÇÃO DA SOLUÇÃO VENCEDORA**

O grupo vencedor do Challenge John Deere demonstrou um notável desempenho. A sua abordagem abrangeu a aplicação de diversos modelos preditivos, que, embora mais simples em sua complexidade, desempenharam um papel fundamental no sucesso da solução. O grande destaque da solução vencedora foi a sua interface de usuário, que foi habilmente projetada para organizar e apresentar os dados previstos pelos modelos preditivos.

A interface do grupo vencedor proporcionou uma experiência única de visualização e compreensão dos dados previstos. Ela não apenas apresentou informações de maneira clara e acessível, mas também facilitou a comparação e a análise das projeções em diversos contextos. Essa abordagem inovadora de apresentação de dados proporcionou à JD uma ferramenta poderosa para o seu planejamento estratégico e tomada de decisões informadas.

### **3. MOTIVOS DA ESCOLHA PELA JD**

A escolha do grupo vencedor, AgroVisionaries, pela JD repousa em méritos indiscutíveis. O motivo fundamental para a sua seleção foi a qualidade excepcional da interface de usuário, que permitiu uma compreensão aprofundada dos dados de produção agrícola previstos pelos modelos preditivos.

Além da interface, os conjuntos de modelos preditivos empregados pelo grupo vencedor desempenharam um papel fundamental ao fornecer dados precisos e confiáveis para a JD. Isso contribuiu significativamente para a tomada de decisões informadas no âmbito do negócio da JD, promovendo uma otimização eficaz dos recursos e uma estratégia mais precisa.

A solução vencedora não apenas atendeu, mas superou as expectativas da JD ao oferecer um conjunto valioso de ferramentas para aprimorar a eficiência operacional e o planejamento estratégico da empresa no setor agrícola. A JD optou pela solução vencedora como resultado do seu impacto significativo nos processos de negócios, garantindo assim uma vantagem competitiva notável.

### **4. COMPARAÇÃO COM A ENTREGA DO SEU GRUPO**

Em nosso protótipo, criamos um modelo que analisava dados passados para prever a produtividade de um mês e ano específicos. Optamos por usar um único modelo complexo para essa tarefa. No entanto, ao observar a solução vencedora, notamos uma abordagem diferenciada.

O grupo vencedor escolheu utilizar vários modelos de previsão, o que resultou em um desempenho superior nas previsões. A decisão deles em adotar múltiplos modelos provou ser mais eficaz e resultou em projeções mais precisas. Isso nos mostrou a importância da diversificação de modelos para melhorar nossos resultados em desafios de Machine Learning.

Esta comparação enfatiza a necessidade de flexibilidade e criatividade ao abordar problemas complexos, fornecendo insights valiosos para o nosso aprendizado contínuo.

## 5. CONCLUSÃO

O desafio da John Deere proporcionou valiosos insights sobre a aplicação de Machine Learning no setor agrícola. A solução vencedora se destacou ao utilizar diversos modelos de previsão, resultando em projeções mais precisas. A escolha da JD em favor dessa solução se deveu à qualidade da interface de usuário e ao valor dos modelos diversos.

Nossa entrega, embora valiosa, poderia ter se beneficiado de uma abordagem mais diversificada e flexível. Aprendemos que a diversificação de modelos pode levar a melhores resultados em desafios de Machine Learning.

À medida que continuamos nossa jornada de aprendizado, levamos conosco lições que nos ajudarão a enfrentar desafios futuros com criatividade e confiança.

## **SUMÁRIO – Projeto Drone**

**1. INTRODUÇÃO**

**2. FAZER O YOLO COM MAKESENSE.AI**

**3. SEPARAR IMAGENS E YOLO PARA TREINO, VALIDAÇÃO E TESTE**

**4. RODAR OS CÓDIGOS PARA CRIAR O BEST.PT**

**5. COMPETIÇÃO DO DRONE**

**6. CONCLUSÃO**

## **1. INTRODUÇÃO**

Este é um relatório de análise sobre o projeto e competição de drones de reconhecimento que ocorreu no evento FIAP NEXT em 28 de outubro de 2023. O projeto consistiu em uma competição de grupos do primeiro ano do curso de IA em que o objetivo era criar um modelo de Inteligência Artificial capaz de reconhecer peças de tratores pré-definidas da empresa parceira da FIAP neste projeto, a John Deere.

A disputa era pelo maior número de peças reconhecidas, e também pela acurácia de cada reconhecimento de peça. Portanto, o desafio de nós, alunos, era de deixar o modelo preciso o suficiente para conseguir reconhecer a maioria das cinco peças escolhidas, levando-se em conta a precisão/certeza do modelo no cálculo dos pontos.

## **2. FAZER O YOLO COM MAKESENSE.AI**

Para criar o modelo YOLO, foram capturadas aproximadamente 400 fotos das peças de tratores fornecidas. Essas imagens serviram como o conjunto de dados para treinamento do modelo.

Cada imagem foi renomeada e rotulada com as categorias das peças que deveriam ser reconhecidas. Definir as labels foi crucial, pois ele precisa aprender a associar as características visuais das peças às categorias corretas.

Todas as imagens foram enquadradas e preparadas para o treinamento com a ajuda do site Makesense.ai, que permite este enquadramento e também permite associá-las aos labels.



### 3. SEPARAR IMAGENS E YOLO PARA TREINO, VALIDAÇÃO E TESTE

As imagens e seus respectivos rótulos foram divididos em três pastas:

Treinamento (train): As imagens usadas para treinar o modelo. O modelo aprende com essas imagens e tenta associar as características das peças às categorias corretas.

Validação (val): Um conjunto menor de imagens usado para avaliar o desempenho do modelo durante o treinamento. Isso ajuda a ajustar hiperparâmetros e evitar o overfitting.

Teste (test): Um conjunto separado de imagens que não foi visto pelo modelo durante o treinamento. Essas imagens são usadas para avaliar o desempenho final do modelo.

### 4. RODAR OS CÓDIGOS PARA CRIAR O BEST.PT

Este código monta o Google Drive no ambiente do Colab para que você possa acessar os arquivos armazenados no Google Drive:

```
from google.colab import drive
drive.mount('/content/drive')
```

Isso clona o repositório YOLOv5 do GitHub para o ambiente atual:

```
! git clone https://github.com/ultralytics/yolov5.git
```

Isso instala as dependências necessárias para o projeto YOLOv5 com base no arquivo requirements.txt:

```
! pip install -r yolov5/requirements.txt
```

Isso copia o arquivo de configuração YAML do modelo YOLOv5 para a pasta de dados do projeto e inicia o treinamento do modelo YOLOv5 usando o arquivo de configuração trator.yaml, inicializando com pesos pré-treinados, treinando por 40 épocas:

```
! cp /content/drive/MyDrive/IACS/Sprint1/trator.yaml yolov5/data/
! python yolov5/train.py --data trator.yaml --weights yolov5s.pt --img 640 --epochs 40
```

Esta função procura a pasta mais recente no diretório yolov5/runs/train que contém os resultados do treinamento. Além disso, executa a detecção de objetos usando o modelo treinado. Ele utiliza os pesos do modelo no diretório best.pt na pasta mais recente de treinamento e aplica a detecção nas imagens do diretório tests/:

```
import os
import subprocess

def get_latest_train_run_folder():
    subfolders = [f.path for f in os.scandir('yolov5/runs/train')
if f.is_dir()]
    latest_folder = max(subfolders, key=os.path.getctime,
default=None)
    return latest_folder

latest_run = get_latest_train_run_folder()

# COMANDO

result = subprocess.run(f'python yolov5/detect.py --weights
{latest_run}/weights/best.pt --img 640 --source tests/ --data
yolov5/data/trator.yaml', shell=True)
```

E por fim, depois de rodar todas as células de código, temos o arquivo 'best.pt' que contém todas as informações sobre treinamento, validação e teste necessários para a detecção de objetos, que, no caso, se trata do modelo pronto de machine learning em si.

Após todo o processo de desenvolvimento do modelo YOLO para reconhecimento de peças de tratores, chegamos à etapa da competição de drones.

## 5. COMPETIÇÃO DO DRONE

Durante a competição de drones, o modelo YOLO treinado foi implantado para reconhecer as peças de tratores. Os resultados da competição revelaram que o modelo foi capaz de reconhecer uma peça, mas não conseguiu identificar as outras quatro peças.

Um problema notável que surgiu durante a competição foi a possível inversão ou confusão nos rótulos das peças. As acurácias das detecções estavam excepcionalmente altas, o que levanta a suspeita de que as categorias das peças podem ter sido associadas incorretamente pelo modelo do nosso grupo.

## 6. CONCLUSÃO

Em conclusão, o projeto e competição de drones de reconhecimento de peças de tratores representou um desafio significativo para nós. Achemos que nosso modelo tinha uma boa chance de ficar na frente se não fosse pela confusão de labels. Embora o modelo tenha sido capaz de reconhecer uma peça, a dificuldade em identificar as outras peças destaca a importância de uma preparação completa dos dados, ajuste e validação rigorosa do modelo. O processo de aprendizado com esses desafios é valioso e pode ser usado para melhorar nossos futuros projetos.

No futuro, é crucial que revisemos e aprimoremos o processo de treinamento do modelo, assegurando que as etiquetas estejam corretamente vinculadas às peças e que o modelo tenha a capacidade de se adaptar a diferentes condições de iluminação e variações nas peças. É essencial aprender com os erros que encontramos e continuamente aperfeiçoar o modelo, visando a um desempenho mais consistente e preciso em competições semelhantes.